

Instituto de Educación Superior de Educación Técnica y Formación Profesional



Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial

Validación Cruzada

Aprendizaje Automático I

Docente: Di Nubila, Jose

Alumnos:

- Ravarotto, Iván Tomás
- Santagata, Julian Gabriel
- Drocezesky, Clara Denise

Ciclo 2026

Índice general

1. Resumen (Página 2)
2. Introducción (Página 3)
3. ¿Qué es la Validación Cruzada? (Página 3)
4. Objetivos y Aplicaciones Fundamentales (Página 4)
5. Funcionamiento Matemático y Algorítmico
6. Tipos y Estrategias de Validación Cruzada
7. Métricas de Evaluación en Validación Cruzada
8. Implementación Técnica en Scikit-Learn
9. Balance Comparativo de Ventajas y Limitaciones
10. Sección Ampliada: Fundamentos Avanzados y Buenas Prácticas
11. Glosario de Términos Clave
12. Referencias Bibliográficas (Formato APA 7)

Resumen

Este documento presenta una guía académica integral sobre la Validación Cruzada (Cross Validation) en Machine Learning. Se examinan sus fundamentos teóricos, los objetivos clave como la prevención del sobreajuste (overfitting) y subajuste (underfitting), y las distintas metodologías de particionado (K-Fold, Stratified K-Fold, TimeSeriesSplit, entre otras). Asimismo, se aborda la evaluación mediante métricas estándar, la implementación técnica en Scikit-Learn utilizando pipelines para evitar la fuga de información (Data Leakage), y estrategias avanzadas como la validación anidada (Nested CV) y el compromiso sesgo-varianza

Validación Cruzada (Cross Validation)

“” Fundamentos teóricos, variantes metodológicas, optimización de hiper parámetros, prevención de Data Leakage, implementación en Scikit-Learn y referencias bibliográficas

Síntesis del documento: Material integral de estudio y preparación para exposición universitaria. Fundamentado rigurosamente en la literatura clásica del aprendizaje estadístico (Hastie, James, Kohavi, Bishop, Mitchell, Breiman) y la documentación oficial de Scikit-Learn. Esta versión ampliada profundiza en la interpretación estadística de métricas, diagnóstico de curvas de aprendizaje, validación anidada (Nested CV), prevención técnica de fuga de información (Data Leakage) y buenas prácticas en producción. “” ← ¿Lo dejamos o borramos?

1. Introducción

En Machine Learning, el objetivo de un modelo no es únicamente aprender los datos con los que fue entrenado, sino ser capaz de generalizar, es decir, realizar predicciones correctas sobre datos nuevos e independientes que nunca ha visto durante la fase de optimización.

Uno de los errores más comunes consiste en evaluar un modelo utilizando el mismo conjunto de datos con el que fue entrenado. En ese caso, el modelo puede obtener resultados aparentemente excelentes simplemente porque ha memorizado los ejemplos de entrenamiento, fenómeno conocido como **sobreajuste (overfitting)**.

La validación cruzada surge como una técnica fundamental para estimar el rendimiento real de un modelo utilizando distintas particiones del conjunto de datos. En lugar de depender de una única división entre entrenamiento y prueba, el modelo se entrena y evalúa varias veces sobre diferentes subconjuntos, obteniendo una medida sustancialmente más confiable de su capacidad de generalización.

Fuentes: James et al. (2021) *An Introduction to Statistical Learning*; Hastie et al. (2009) *The Elements of Statistical Learning*; Documentación oficial de Scikit-Learn.

2. ¿Qué es la Validación Cruzada?

La validación cruzada (Cross Validation) es un método estadístico riguroso utilizado para evaluar el desempeño de un modelo predictivo. Consiste en dividir el conjunto de datos en varios subconjuntos llamados folds.

Durante el proceso, el modelo se entrena utilizando una parte de los datos y se evalúa sobre la parte restante. Este procedimiento se repite tantas veces como folds existan, de manera que cada subconjunto actúe exactamente una vez como conjunto de prueba. Finalmente, las métricas obtenidas en todas las iteraciones se promedian para obtener una estimación insesgada del rendimiento del modelo.

Definición formal: La validación cruzada estima el error de generalización mediante múltiples particiones disjuntas de entrenamiento y prueba, reduciendo de manera sustancial la dependencia y el sesgo de una única división aleatoria del conjunto de datos.

3. Objetivos y Aplicaciones Fundamentales

La validación cruzada cumple diversas funciones cruciales dentro del flujo de trabajo de Machine Learning

3.1 Evaluar el desempeño real del modelo

Su principal función consiste en estimar cómo se comportará el modelo frente a datos desconocidos, midiendo capacidad predictiva en lugar de capacidad de memorización.

3.2 Detección de Overfitting (Sobreajuste)

Discrepancia alta entre métricas de entrenamiento y validación:

- **Train Accuracy:** 99%
- **CV Accuracy Promedio:** 82%

Conclusión: El modelo memorizó el set de entrenamiento perdiendo capacidad predictiva.

3.3 Detección de Underfitting (Subajuste)

Bajo rendimiento tanto en entrenamiento como en validación:

- **Train Accuracy:** 60%
- **CV Accuracy Promedio:** 58%

Conclusión: El modelo carece de capacidad/ complejidad para capturar los patrones de los datos.

Permite contrastar arquitecturas algorítmicas (por ejemplo, Árboles de Decisión, Random Forest, SVM y Regresión Logística) sobre idénticas particiones de datos, garantizando una comparación estadísticamente justa e independiente de la suerte del muestreo.

3.2 Medición de la estabilidad y consistencia del modelo

Además de la media, permite analizar la varianza de los resultados entre folds:

Modelo A (Consistente / Estable)

Folds: 90% | 91% | 89% | 90% | 91%

Desviación estándar baja ($\pm 0.7\%$): alta fiabilidad en producción y baja sensibilidad a variaciones muestrales.

Modelo B (Sensible / Inestable)

Folds: 65% | 98% | 74% | 93% | 81%

Desviación estándar alta ($\pm 13.5\%$): alta sensibilidad a la muestra; riesgo significativo de comportamientos anómalos.

4. Funcionamiento Matemático y Algorítmico

Consideremos un conjunto de datos con $N = 1000$ observaciones. Al seleccionar $k = 5$ folds, los datos se particionan en cinco bloques disjuntos de 200 observaciones cada uno:

Iteración	Folds de Entrenamiento (800 obs.)	Fold de Prueba (200 obs.)
Iteración 1	Fold 2, Fold 3, Fold 4, Fold 5	Fold 1
Iteración 2	Fold 1, Fold 3, Fold 4, Fold 5	Fold 2
Iteración 3	Fold 1, Fold 2, Fold 4, Fold 5	Fold 3
Iteración 4	Fold 1, Fold 2, Fold 3, Fold 5	Fold 4
Iteración 5	Fold 1, Fold 2, Fold 3, Fold 4	Fold 5

Al completar las iteraciones, la métrica global agregada (por ejemplo, el *Accuracy* promedio) se formaliza analíticamente mediante:

$$Accuracy_{promedio} = \frac{1}{5} \sum_{i=1}^5 Accuracy_i = \frac{Accuracy_1 + Accuracy_2 + \dots + Accuracy_5}{5}$$

Este valor representa una estimación insesgada del rendimiento esperado del modelo sobre la distribución de datos no observada.

Ejemplo: predecir si un estudiante aprobará

Una universidad quiere desarrollar un modelo de Machine Learning que **prediga si un estudiante aprobará un examen**, utilizando datos como horas de estudio, asistencia y cantidad de trabajos entregados.

Cuenta con información de **100 estudiantes** y utiliza una validación cruzada de **5 partes (5-Fold)**.

1. Divide los 100 estudiantes en **5 grupos de 20**.
2. Entrena el modelo con 80 estudiantes y lo evalúa con los 20 restantes.
3. Repite el proceso 5 veces, haciendo que cada grupo sea utilizado una vez como conjunto de evaluación.
4. Obtiene los siguientes resultados: **88%, 92%, 90%, 91% y 89%**.
5. El promedio es de **90% de precisión**.

¿Qué nos permite saber?

La validación cruzada permite comprobar que el modelo funciona correctamente con **distintos grupos de estudiantes**, reduciendo el riesgo de que el resultado dependa únicamente de un grupo específico de datos.

5. Tipos y Estrategias de Validación Cruzada



6. Métricas de Evaluación en Validación Cruzada

En cada fold se calculan las métricas pertinentes de acuerdo a la naturaleza de la tarea analítica, consolidando luego su media y dispersión:

- **Accuracy:** Proporción de aciertos globales sobre el total de predicciones.
- **Precision:** Calidad de las predicciones positivas: $VP / (VP + FP)$.
- **Recall (Sensibilidad):** Cobertura de la clase real positiva: $VP / (VP + FN)$.
- **F1-score:** Media armónica entre Precision y Recall: $2 \times (P \times R) / (P + R)$.
- **ROC-AUC:** Capacidad discriminativa global frente a variaciones de umbral.
- **Matriz de Confusión:** Desagregación detallada de aciertos y tipos de error (Tipo I y II).

7. Implementación Técnica en Scikit-Learn

Scikit-Learn provee funciones modulares integradas para orquestar la validación:

7.1 cross_val_score() — Evaluación rápida de métrica única

```
from sklearn.model_selection import cross_val_score
from sklearn.ensemble import RandomForestClassifier

modelo = RandomForestClassifier(n_estimators=100, random_state=42)
scores = cross_val_score(modelo, X, y, cv=5, scoring="accuracy")

print("Accuracy promedio:", scores.mean())
print("Desviación estándar:", scores.std())
```

7.2 cross_validate() — Métricas múltiples y registro de cómputo

```
from sklearn.model_selection import cross_validate

cv_results = cross_validate(
    modelo,
    X,
    y,
    scoring=["accuracy", "precision_macro", "recall_macro", "f1_macro"],
    cv=5,
    return_train_score=True
)

print("Test F1 Macro:", cv_results["test_f1_macro"].mean())
print("Train F1 Macro:", cv_results["train_f1_macro"].mean()) # Permite auditar overfitting
```

7.3 cross_val_predict() — Predicciones fuera de muestra

Genera predicciones fuera de muestra (*out-of-fold*) para cada muestra del dataset. Resulta idónea para inspeccionar visualmente la matriz de confusión agregada o gráficos de residuos en regresión. *Advertencia metodológica:* no debe utilizarse directamente para inferir el error de generalización estándar del modelo.

7.4 Iteradores de Partición (Splitters) en Scikit-Learn

Disponibles en `sklearn.model_selection`: `KFold`, `StratifiedKFold`, `RepeatedKFold`, `RepeatedStratifiedKFold`, `LeaveOneOut`, `LeavePOut`, `ShuffleSplit`, `StratifiedShuffleSplit`, `GroupKFold`, `StratifiedGroupKFold` y `TimeSeriesSplit`.

8. Balance Comparativo de Ventajas y Limitaciones

Ventajas Principales

- Estimación insesgada y altamente confiable del rendimiento en generalización.
- Elimina la dependencia del sesgo de una partición aleatoria única.
- Aprovecha eficientemente todo el volumen muestral disponible.
- Proporciona una plataforma equitativa para contrastar arquitecturas algorítmicas.
- Facilita la detección temprana y precisa de sobreajuste (overfitting) y subajuste (underfitting).
- Constituye el estándar riguroso para la búsqueda de hiper parámetros.

Limitaciones y Consideraciones Críticas

- Costo computacional multiplicado por k al entrenar modelos independientes.
- Inadecuada en su variante tradicional para series temporales (exige TimeSeriesSplit).
- Innecesaria en entornos de *Big Data* extremo, donde un Hold-Out con millones de filas basta.
- Riesgo letal de fuga de información (*Data Leakage*) si el preprocesamiento no se encapsula en cada fold.

9. Sección Ampliada: Fundamentos Avanzados y Buenas Prácticas

9.1 El Compromiso Sesgo-Varianza (Bias-Variance Tradeoff) en Validación Cruzada

El valor del hiperparámetro k controla el balance fundamental entre sesgo y varianza de la estimación del error:

•

Valores bajos de k (ej. $k = 2$ ó $k = 3$): El modelo se entrena con menor porcentaje de datos (50% a 66%), lo que tiende a *sobrestimar* el error de generalización (mayor sesgo pesimista), pero la varianza entre estimadores es reducida.

•

Valores intermedios de k ($k = 5$ ó $k = 10$): Representan el punto óptimo empírico recomendado por Hastie et al. (2009) y Kohavi (1995), logrando un compromiso equilibrado entre sesgo moderado, varianza controlada y costo computacional viable.

•

Valores altos de k (ej. LOOCV donde $k = N$): El estimador es prácticamente insesgado, pero sufre de una elevada varianza estadística debido a que los N modelos se entrenan con conjuntos de datos que comparten el $(N - 2) / (N - 1)$ de las observaciones, induciendo una alta correlación positiva entre las estimaciones.

9.2 Prevención Rigurosa del Data Leakage (Fuga de Información) mediante Pipelines

El *Data Leakage* ocurre cuando información proveniente del conjunto de validación o prueba se filtra inadvertidamente dentro del proceso de entrenamiento. Un error clásico consiste en aplicar normalización (ej. StandardScaler), imputación de nulos o selección de características sobre todo el dataset **antes** de ejecutar la validación cruzada. En este escenario, las medias y varianzas de los folds de test contaminan el ajuste del modelo, arrojando métricas artificialmente optimistas que fracasan en producción.

x Práctica Incorrecta (Data Leakage)

```
# Error: Scaler aprende media de test scaler =  
StandardScaler()  
X_scaled = scaler.fit_transform(X) scores =
```

```
cross_val_score(model, X_scaled, y)
```

✓ Práctica Correcta (Uso de Pipeline)

```
from sklearn.pipeline import make_pipeline # Correcto:
Scaler se ajusta sólo en train pipe =
make_pipeline(StandardScaler(), model) scores =
cross_val_score(pipe, X, y, cv=5)
```

9.3 Optimización y Validación Anidada (Nested Cross-Validation)

Cuando se utiliza validación cruzada para seleccionar hiperparámetros (por ejemplo, con GridSearchCV) y simultáneamente se reporta el mejor puntaje obtenido como el rendimiento esperado del modelo, se introduce un sesgo de selección optimista.

Para obtener una estimación rigurosa e imparcial del rendimiento de un pipeline optimizado, se recurre a la **Validación Anidada (Nested CV)**:

- **Bucle interno (Inner loop):** Se encarga exclusivamente del afinamiento de hiperparámetros sobre los subfolds de entrenamiento.
- **Bucle externo (Outer loop):** Evalúa el desempeño general del modelo optimizado sobre datos que nunca participaron de la elección de parámetros.

```
from sklearn.model_selection import GridSearchCV, cross_val_score

# Bucle interno: búsqueda de hiperparámetros
inner_cv = KFold(n_splits=3, shuffle=True, random_state=1)
clf = GridSearchCV(estimator=model, param_grid=param_grid, cv=inner_cv)

# Bucle externo: estimación insesgada del rendimiento
outer_cv = KFold(n_splits=5, shuffle=True, random_state=2)
nested_scores = cross_val_score(clf, X=X, y=y, cv=outer_cv)
print("Rendimiento Nested CV insesgado:", nested_scores.mean())
```

Glosario de Términos Clave

Término	Definición
Validación Cruzada (Cross Validation)	Método estadístico para evaluar la capacidad de generalización de un modelo predictivo dividiendo el conjunto de datos en subconjuntos disjuntos de entrenamiento y prueba.
Sobreajuste (Overfitting)	Fenómeno en el cual un modelo memoriza los datos de entrenamiento, obteniendo excelente rendimiento en entrenamiento pero perdiendo capacidad predictiva sobre datos nuevos.
Subajuste (Underfitting)	Situación donde un modelo carece de la complejidad suficiente para capturar la estructura de los datos, registrando un rendimiento deficiente tanto en entrenamiento como en prueba.
Fold	Subconjunto disjunto de observaciones resultante de particionar un conjunto de datos, utilizado alternadamente para entrenamiento o evaluación.
K-Fold Cross Validation	Estrategia de validación que divide el dataset en K partes iguales para entrenar y evaluar el modelo K veces.
Stratified K-Fold	Variante de K-Fold que conserva la proporción de clases de la variable objetivo en cada fold, esencial para conjuntos de datos desbalanceados.
Data Leakage (Fuga de Información)	Error metodológico en el que información del conjunto de prueba/validación contamina el entrenamiento (ej. al aplicar transformaciones antes de dividir los folds), produciendo métricas irrealmente optimistas.
Nested Cross-Validation (Validación Anidada)	Técnica con un bucle interno para la optimización de hiperparámetros y un bucle externo para la evaluación insesgada del rendimiento general.
Pipeline	Estructura en Scikit-Learn que encapsula el preprocesamiento de datos y la estimación del modelo para evitar el Data Leakage durante la validación cruzada.
Compromiso Sesgo-Varianza (Bias-Variance Tradeoff)	Equilibrio fundamental entre el sesgo de la estimación del error y la varianza entre estimadores, controlado en validación cruzada por la elección del número de folds (k).

Referencias Bibliográficas (Formato APA 7)

1. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
2. Breiman, L., & Spector, P. (1992). Submodel Selection and Evaluation in Regression: The X-random Case. *International Statistical Review / Revue Internationale de Statistique*, 60(3), 291-319.
3. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
4. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: with Applications in R/Python* (2nd ed.). Springer.
5. Kohavi, R. (1995). A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. *International Joint Conference on Artificial Intelligence (IJCAI)*, 14(2), 1137-1145.
6. Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- 7.

Rao, R. B., Fung, G., & Rosales, R. (2008). On the Dangers of Cross-Validation: An Experimental Evaluation. *SIAM International Conference on Data Mining*, 588-596.

8.

Scikit-Learn Developers. (s.f.). *Cross-validation: evaluating estimator performance*. Scikit-learn Documentation.